Medidas resumo

Wagner H. Bonat Elias T. Krainski Fernando P. Mayer

Universidade Federal do Paraná Departamento de Estatística Laboratório de Estatística e Geoinformação







Sumário

- Introdução
- Medidas de posição
 - Medidas de posição para um conjunto de dados
 - Medidas de posição para VAs discretas
- Medidas de dispersão
 - Medidas de dispersão para um conjunto de dados
 - Medidas de dispersão para VAs discretas
- 4 Exercícios recomendados

Introdução

Características importantes de qualquer conjunto de dados ou de uma variável aleatória

- Centro
- Variação
- Distribuição
- Valores atípicos

Introdução

Características importantes de qualquer conjunto de dados ou de uma variável aleatória

- Centro
- Variação
- Distribuição
- Valores atípicos

Classificaremos as medidas descritivas em dois grupos

- de posição
- de dispersão

Sumário

- Introdução
- Medidas de posição
 - Medidas de posição para um conjunto de dados
 - Medidas de posição para VAs discretas
- Medidas de dispersão
 - Medidas de dispersão para um conjunto de dados
 - Medidas de dispersão para VAs discretas
- 4) Exercícios recomendados

Definição

- medidas de posição central
 - úteis para **resumo** e **análise** de dados
 - Média, Mediana, Moda
- outras medidas de posição
 - extremos: mínimo, máximo
 - quantis: 1° quartil, 3° quartil, percentil 5%, entre outras

LEG/DEST/UFPR Medidas resumo

Moda

Valor mais frequente em um conjunto de dados

- Dependendo do conjunto de dados, ele pode ser
 - Sem moda quando nenhum valor se repete
 - Unimodal quando existe apenas um valor repetido com maior frequência
 - Bimodal quando existem dois valores com a mesma maior frequência
 - Multimodal quando mais de dois valores se repetem com a mesma frequência

Moda

Valor mais frequente em um conjunto de dados

- Dependendo do conjunto de dados, ele pode ser
 - Sem moda quando nenhum valor se repete
 - Unimodal quando existe apenas um valor repetido com maior frequência
 - Bimodal quando existem dois valores com a mesma maior frequência
 - Multimodal quando mais de dois valores se repetem com a mesma frequência

Valor com maior probabilidade de ocorrer numa VA discreta

- Ex.: lançamento de duas moedas
 - X: número de caras, $X = \{0, 1, 2\}$
 - P(x) = 0.25, 0.5 e 0.25, respectivamente
 - o moda: 1

LEG/DEST/UFPR Medidas resumo 6/

Mediana

O valor do meio da amostra ordenada

 Separa o conjunto de dados em duas partes iguais, 50% abaixo e 50% acima

Observações ordenadas:

• a menor observação por $x_{(1)}$, a segunda por $x_{(2)}$, e assim por diante:

$$x_{(1)} \le x_{(2)} \le \cdots \le x_{(n-1)} \le x_{(n)}$$

As observações odenadas são chamadas de estatísticas de ordem

- $x_{(1)}$ é o mínimo da amostra
- $x_{(n)}$ é o máximo da amostra

Média de dados brutos

Divide-se a soma de todos os dados pelo número total deles:

$$\bar{x}_{obs} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^{n} x_i}{n}.$$

Média de dados agrupados

Soma dos produtos dos valores pelas respectivas frequências e divide pela frequência total

$$\bar{x}_{obs} = \frac{n_1 x_1 + n_2 x_2 + \dots + n_k x_k}{n_1 + n_2 + \dots + n_k} = \frac{\sum_{i=1}^k n_i x_i}{n}.$$

Exemplo: média de dados discretos agrupados

Considere a tabela de frequência abaixo:

Número	n _i	f_i
0	4	0,20
1	5	0,25
2	7	0,35
3	3	0,15
5	1	0,05
Total	20	1

A média é calculada por:

$$ar{x}_{obs} = rac{0 \cdot 4 + 1 \cdot 5 + 2 \cdot 7 + 3 \cdot 3 + 5 \cdot 1}{4 + 5 + 7 + 3 + 1} = rac{33}{20} = 1,65$$

Exemplo: média de dados agrupados em classes

Usar ponto médio de cada classe e respectivas frequências

Classe	$PM = x_i$	n _i	f _i
[4, 8)	6	10	0,278
[8, 12)	10	12	0,333
[12, 16)	14	8	0,222
[16, 20)	18	5	0,139
[20, 24)	22	1	0,028
Total	36	1	

Considerando os pontos médios de cada classe, a média é calculada por

$$\bar{x}_{obs} = \frac{\left(6 \cdot 10 + 10 \cdot 12 + \dots + 22 \cdot 1\right)}{10 + 12 + 8 + 5 + 1}$$

$$= \frac{404}{36}$$

$$= 11, 22$$

Exemplo 4.1

Suponha que parafusos a serem utilizados em tomadas elétricas são embalados em caixas rotuladas como contendo 100 unidades. Em uma construção, 10 caixas de um lote tiveram o número de parafusos contados, fornecendo os valores:

98, 102, 100, 100, 99, 97, 96, 95, 99 e 100

Calcular média, mediana e moda.

- $\bar{x}_{obs} = 98.6$.
- $md_{obs} = 99$.
- $mo_{obs} = 100$.

Média e mediana


Notar a influência de valores extremos na média (se ao invés de 95, o valor fosse 45):


95 96 97 98 99 99 100 100 100 102
$$\Rightarrow \bar{x}_{obs} = 98, 6 \text{ e } Md = 99$$


45 96 97 98 99 99 100 100 100 102
$$\Rightarrow \bar{x}_{obs} = 93,6 \text{ e } Md = 99$$

Devido a esse fato, a mediana é uma medida de posição central **robusta**, ou seja, *não influenciada por valores extremos*.

Média, mediana e moda







LEG/DEST/UFPR Medidas resumo

Exemplo 4.4

Um estudante está procurando um estágio para o próximo ano. As companhias A e B têm programas de estágios e oferecem uma remuneração por 20 horas semanais com as seguintes características.

Companhia	Α	В
média	2,5	2,0
mediana	1,7	1,9
moda	1,5	1,9

Qual companhia você escolheria?

Exemplo 4.3

Foram coletadas 150 observações da variável X, representando o número de vestibulares FUVEST (um por ano) que um mesmo estudande prestou. Com os dados da tabela abaixo, calcule as medidas de posição de X.

Χ	n _i
1	75
2	47
3	21
4	7

Suponha ainda que o interesse é estudar o gasto dos alunos associado com as despesas do vestibular. Para simplificar, suponha que se atribui para cada aluno, uma despesa fixa de R\$ 1300,00 relativa a preparação e mais R\$ 50 para cada vestibular prestado. Calcule as medidas de posição central para a variável D (despesa com vestibular).

Medidas de posição para VAs discretas

Sabemos que a descrição completa do comportamento de uma VA discreta é feita através de sua **função de probabilidade**.

Assim como fizemos para um conjunto de dados qualquer, podemos obter as medidas de posição para qualquer variável aleatória.

Lembrando que se os possíveis valores de uma VA X são x_1, x_2, \ldots, x_k , com correspondentes probabilidades p_1, p_2, \ldots, p_k , então as medidas de posição podem ser definidas a seguir.

Medidas de posição para VAs discretas

A Média é chamada de valor esperado ou esperança

$$E(X) = \sum_{i=1}^k x_i p_i.$$

A Mediana é o valor Md que satisfaz as seguintes condições

$$P(X \le Md) \ge 1/2$$
 e $P(X \ge Md) \ge 1/2$.

A Moda é o valor (ou valores) com maior probabilidade de ocorrência

$$P(X = Mo) = \max\{p_1, p_2, ..., p_k\}.$$

Exemplo 4.5

Considere a VA X com a seguinte função discreta de probabilidade:

Calcule as medidas de tendência central.

Exemplo 4.6

Considere uma VA X com função de probabilidade dada por

Calcule as medidas de posição para a VA Y = 5X - 10.

Sumário

- Introdução
- Medidas de posição
 - Medidas de posição para um conjunto de dados
 - Medidas de posição para VAs discretas
- Medidas de dispersão
 - Medidas de dispersão para um conjunto de dados
 - Medidas de dispersão para VAs discretas
- 4 Exercícios recomendados


Introdução

O resumo de um conjunto de dados exclusivamente por uma medida de centro, **esconde** toda a informação sobre a variabilidade do conjunto de observações.

Não é possível analisar um conjunto de dados apenas através de uma medida de tendência central.

Por isso precisamos de medidas que resumam a variabilidade dos dados em relação à um valor central.

Exemplo: mesma média, diferente dispersão



LEG/DEST/UFPR

Exemplo

Cinco grupos de alunos se submeteram a um teste, obtendo as seguintes notas

Grupo	Notas	\bar{x}
A	3, 4, 5, 6, 7	5
В	1, 3, 5, 7, 9	5
C	5, 5, 5, 5, 5	5
D	3, 5, 5, 7	5
Е	3, 5, 5, 6, 6	5

O que a média diz a respeito das notas quando comparamos os grupos?

Definição

São medidas estatísticas que caracterizam o quanto um conjunto de dados está disperso em torno de sua tendência central.

Ferramentas para resumo e análise de dados:

- Amplitude
- Desvio-médio (ou mediano)
- Variância
- Desvio-padrão
- Coeficiente de Variação

Amplitude

A **amplitude** de um conjunto de dados é a diferença entre o maior e o menor valor:

$$\Delta = \max - \min = x_{(n)} - x_{(1)}$$

Grupo	Notas	Δ
Α	3, 4, 5, 6, 7	4
В	1, 3, 5, 7, 9	8
C	5, 5, 5, 5, 5	0
D	3, 5, 5, 7	4
Е	3, 5, 5, 6, 6	3

- Apenas usar máximo e mínimo torna sensível a valores extremos
 - Melhor medida de variabilidade: considerar todos os dados disponíveis
 - Desvio de cada valor em relação à uma medida de posição central (média ou mediana)

LEG/DEST/UFPR Medidas resumo 26 / 40

Desvio médio e mediano

Um resumo da variabilidade: média dos desvios absolutos

• Desvio mediano: a mediana como medida de posição central

desvio mediano =
$$\frac{1}{n} \sum_{i=1}^{n} |x_i - md_{obs}|$$
.

Desvio médio: a média como medida de posição central

desvio médio =
$$\frac{1}{n} \sum_{i=1}^{n} |x_i - \bar{x}_{obs}|$$
.

Exemplo: Desvio médio

Considere as notas do grupo A do exemplo acima ($\bar{x}_{obs} = 5$)

O desvio médio (DM) pode ser calculado da seguinte forma:

Grupo A	$x_i - \bar{x}$	$ x_i - \bar{x} $
3	-2	2
4	-1	1
5	0	0
6	1	1
7	2	2
Soma	0	6

$$DM = \frac{1}{n} \sum_{i=1}^{n} |x_i - \bar{x}_{obs}| = \frac{6}{5} = 1, 2$$

O desvio médio é baseado em uma operação **não algébrica** (módulo), o que torna mais difícil o estudo de suas propriedades.

Variância e desvio-padrão de um conjunto de dados

Uma alternativa melhor é usar a **soma dos quadrados dos desvios**, que dá origem à **variância** de um conjunto de dados

$$var_{obs} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x}_{obs})^2$$

Para manter a mesma unidade de medida dos dados originais, definimos o desvio padrão como

$$dp_{obs} = \sqrt{var_{obs}}$$

Uma expressão alternativa da variância (mais fácil de calcular) é

$$var_{obs} = \frac{1}{n} \sum_{i=1}^{n} x_i^2 - \bar{x}_{obs}^2$$

Exemplo

No exemplo anterior

Grupo A	$x_i - \bar{x}$	$ x_i - \bar{x} $	$(x_i - \bar{x})^2$	x_i^2
3	-2	2	4	9
4	-1	1	1	16
5	0	0	0	25
6	1	1	1	36
7	2	2	4	49
Soma	0	6	10	135

A variância é

$$var_{obs} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x}_{obs})^2 = \frac{10}{5} = 2.$$

Ou, usando a fórmula alternativa

$$var_{obs} = \frac{1}{n} \sum_{i=1}^{n} x_i^2 - \bar{x}_{obs}^2 = \frac{135}{5} - 5^2 = 2.$$

Coeficiente de variação

O coeficiente de variação para um conjunto de dados é definido por

$$cv_{obs} = \frac{dp_{obs}}{\bar{x}_{obs}}$$

É uma medida **adimensional**, e geralmente apresentada na forma de porcentagem.

No exemplo anterior: $dp_{obs} = \sqrt{var_{obs}} = \sqrt{2} = 1,414214.$

Portanto:

$$cv_{obs} = \frac{dp_{obs}}{\bar{x}_{obs}} = \frac{1,414214}{5} = 0,2828427 \approx 28,3\%$$

Variância em tabelas de frequência

Assim como no caso da média, se tivermos n observações da variável X, das quais n_1 são iguais a x_1 , n_2 são iguais a x_2 , ..., n_k são iguais a x_k , então a variância pode ser definida por:

$$var_{obs}(X) = \frac{1}{n} \sum_{i=1}^{k} n_i (x_i - \bar{x}_{obs})^2$$

Ou, pela fórmula alternativa:

$$var_{obs}(X) = \frac{1}{n} \sum_{i=1}^{k} n_i x_i^2 - \bar{x}_{obs}^2$$

Exemplo

Como exemplo, considere a tabela de frequência abaixo ($\bar{x} = 1,65$):

Número	n _i	f _i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
0	4	0,20	-1,65	2,72
1	5	0,25	-0,65	0,42
2	7	0,35	0,35	0,12
3	3	0,15	1,35	1,82
5	1	0,05	3,35	11,22
Total	20	1		

A variância pode ser calculada por:

$$var_{obs} = \frac{(4 \cdot 2, 72 + 5 \cdot 0, 42 + \dots + 1 \cdot 11, 22)}{4 + 5 + 7 + 3 + 1}$$

$$= \frac{30, 55}{20}$$

$$= 1,528$$

Exemplo

Considere a seguinte tabela de distribuição de frequência ($\bar{x} = 11, 22$):

Classe	$PM = x_i$	ni	f _i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
[4, 8)	6	10	0,278	-5,222	27,272
[8, 12)	10	12	0,333	-1,222	1,494
[12, 16)	14	8	0,222	2,778	7,716
[16, 20)	18	5	0,139	6,778	45,938
[20, 24)	22	1	0,028	10, 778	116,160
Total		36	1		

Considerando os **pontos médios** de cada classe como os valores x_i , a variância pode ser calculada por

$$var_{obs} = \frac{(10 \cdot 27, 272 + 12 \cdot 1, 494 + \dots + 1 \cdot 116, 160)}{10 + 12 + 8 + 5 + 1}$$
$$= \frac{698, 22}{36} = 19,395$$

Exemplo 4.9

No Exemplo 4.3, definimos a quantidade D, despesa no vestibular, obtida a partir de X pela expressão D=50X+1300, com X indicando o número de vestibulares prestados.

Χ	n _i
1	75
2	47
3	21
4	7

Calcule a variância de D.

Fazer também: Exemplo 4.10.

Variância de uma VA discreta

Calcula o valor esperado: $\mu = E(X) = \sum_{i=1}^{k} x_i p_i$

Multiplica o quadrado dos desvios em torno do valor esperado pela probabilidade e soma

$$Var(X) = \sum_{i=1}^{k} (x_i - \mu)^2 p_i$$

Alternativamente, podemos usar

$$Var(X) = E[(X - \mu)^2] = E(X^2) - E(X)^2$$

$$com E(X^2) = \sum_{i=1}^k x_i^2 p_i$$

Ver Tabelas resumo 4.2 e 4.3.

Exemplo 4.11

Uma pequena cirurgia dentária pode ser realizada por três métodos diferentes cujos tempos de recuperação (em dias) são modelados pelas variáveis X_1 , X_2 e X_3 . Admita suas funções de probabilidades são dadas por

Calcule as medidas de posição central e dispersão para cada VA e decida sobre o método mais eficiente.

Esperança e variância de modelos teóricos

Calcule a esperança e a variância de X.

• Exemplo 4.15: Seia X com distribuição Binomial de parâmetros n e p

• Exemplo 4.14: Seja X com distribuição Bernoulli de parâmetro p.

- Exemplo 4.15: Seja X com distribuição Binomial de parâmetros n e p.
 Calcule a esperança e a variância de X.
- Ver resultados da Tabela 4.4.

Sumário

- Introdução
- Medidas de posição
 - Medidas de posição para um conjunto de dados
 - Medidas de posição para VAs discretas
- 3 Medidas de dispersão
 - Medidas de dispersão para um conjunto de dados
 - Medidas de dispersão para VAs discretas
- Exercícios recomendados

39 / 40

Exercícios recomendados

- Seção 4.2 1, 2, 3, 4 e 6.
- Seção 4.3 1, 2, 3, 4, 5 e 6.
- Extras: Seção 4.4 2, 4, 7, 10 e 15.